

Universidad — Ingeniería en Computación

Estructuras de Datos

Entrega Parcial

Métricas de Centralidad en Redes

Integrante 1: Nicolás Ricciardi

Integrante 2: Enzo Levancini

Integrante 3: Máximo Beltrán

Junio 2026

Índice

1. Introducción	2
2. Métricas de Centralidad	2
2.1. Degree Centrality	2
2.2. Betweenness Centrality	2
2.3. Closeness Centrality	3
2.4. PageRank	3
2.5. Average Shortest Path	4
2.6. Eigenvector Centrality	4
2.7. Clustering Coefficient	5
3. Datasets Seleccionados	5
3.1. Dataset 1: Yeast Protein-Protein Interaction Network	5
3.2. Dataset 2: Trade Network	6
4. Análisis de Complejidad Teórica	6
4.1. Representación: Lista de Adyacencia	6
4.2. Operaciones sobre el Grafo	6
4.3. Complejidad de las Métricas	7
4.4. Relación entre Métricas	7
5. Estudio Experimental	7
5.1. Metodología y Entorno de Pruebas	7
5.2. Construcción del Grafo	7
5.3. Tiempo de Ejecución por Métrica	8
5.4. Métricas Adicionales: Eigenvector y Clustering Coefficient	9
5.5. Impacto de Modificaciones Estructurales	9
5.6. Análisis de los Resultados	10
6. Conclusiones	10

Introducción

Una **red** es una estructura matemática compuesta por un conjunto de **vértices** (nodos) y un conjunto de **aristas** (relaciones entre nodos). Formalmente, un grafo $G = (V, E)$ donde V es el conjunto de vértices y $E \subseteq V \times V$ el de aristas.

Las redes aparecen de forma natural en muchos dominios:

Dominio	Vértice	Arista
Biología	Proteína	Interacción física
Comercio	País	Flujo comercial
Cine	Actor	Aparición en la misma película
Informática	Dirección IP	Conexión de red

Una pregunta central en el análisis de redes es: *¿cuál elemento es el más “importante”?* La respuesta depende de qué se entiende por importancia. Las **métricas de centralidad** responden esta pregunta desde distintos ángulos, cada una capturando una noción diferente de relevancia estructural.

En este proyecto se implementan **siete métricas de centralidad**, aplicadas sobre dos redes reales: la red de interacciones proteína-proteína de levadura (*Yeast PPI*) y la red de comercio internacional (*Trade Network*).

Métricas de Centralidad

Degree Centrality

Concepto. Un vértice es importante si tiene muchas conexiones directas. Es la métrica más simple y sirve como referencia para comparar con las demás.

Fórmula (grafo no dirigido, normalizada):

$$C_D(v) = \frac{\deg(v)}{n-1}$$

donde $\deg(v)$ es el número de vecinos directos de v y $n = |V|$.

En grafos **dirigidos** se distingue in-degree (aristas entrantes, popularidad) y out-degree (aristas salientes, actividad).

Complejidad: $O(|V| + |E|)$

Aplicación. En la red Yeast PPI, una proteína con alto degree es un *hub* biológico cuya eliminación puede resultar letal para el organismo. En Trade Network, el in-degree refleja diversificación de importaciones y el out-degree el alcance exportador de un país.

Betweenness Centrality

Concepto. Un vértice es importante si actúa como puente en los caminos más cortos entre otros pares. Captura el control sobre el flujo en la red.

Fórmula:

$$C_B(v) = \sum_{\substack{s \neq v \neq t \\ s \neq t}} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

donde σ_{st} es el número total de caminos más cortos entre s y t , y $\sigma_{st}(v)$ los que pasan por v .

Normalización:

$$C_B^{\text{norm}}(v) = \begin{cases} \frac{C_B(v)}{(n-1)(n-2)} & \text{dirigido} \\ \frac{2C_B(v)}{(n-1)(n-2)} & \text{no dirigido} \end{cases}$$

Algoritmo: Brandes [1], que calcula la betweenness exacta para todos los vértices con un BFS por vértice fuente.

Complejidad: $O(|V| \cdot |E|)$

Aplicación. En Yeast PPI, alta betweenness indica proteínas que conectan módulos funcionales distintos; su eliminación puede desconectar regiones de la red. En Trade Network, identifica países que actúan como intermediarios críticos del comercio global.

Closeness Centrality

Concepto. Un vértice es importante si puede alcanzar rápidamente a todos los demás. Se basa en la inversa de la distancia promedio.

Fórmula (Wasserman & Faust [3], para grafos desconectados):

$$C_C(v) = \frac{n-1}{N-1} \cdot \frac{n-1}{\sum_{u \neq v} d(v, u)}$$

donde n es el número de vértices alcanzables desde v , $N = |V|$ el total, y $d(v, u)$ la distancia mínima entre v y u .

El factor $\frac{n-1}{N-1}$ penaliza vértices que no alcanzan al resto, permitiendo comparar en grafos desconectados.

Complejidad: $O(|V| \cdot (|V| + |E|))$ via BFS desde cada vértice.

Aplicación. En Yeast PPI, alta closeness indica proteínas con rol regulatorio global, capaces de transmitir señales al resto de la red en pocas interacciones. En Trade Network, países con alta closeness están integrados eficientemente con la economía mundial.

PageRank

Concepto. Un vértice es importante si está conectado a otros vértices importantes. Un enlace desde un nodo de alto PageRank vale más [2].

Fórmula iterativa:

$$PR(v) = \frac{1-d}{n} + d \sum_{u \in N^-(v)} \frac{PR(u)}{|N^+(u)|}$$

donde $d = 0,85$ es el factor de amortiguación (*damping factor*), $N^-(v)$ son los vecinos que apuntan a v , y $N^+(u)$ los destinos de u .

El término $\frac{1-d}{n}$ modela la probabilidad de salto aleatorio a cualquier nodo. El algoritmo itera hasta convergencia ($\|PR^{(k+1)} - PR^{(k)}\|_1 < 10^{-6}$).

Complejidad: $O(k \cdot (|V| + |E|))$, con $k < 100$ en la práctica.

Aplicación. En Trade Network, el PageRank refleja la importancia de un país en el comercio global ponderada por la importancia de sus socios, capturando influencia indirecta que el degree no detecta. En Yeast PPI, identifica proteínas centrales cuya importancia está reforzada por sus vecinas.

Average Shortest Path

Concepto. Promedio de las distancias mínimas desde un vértice hacia todos los demás alcanzables. Un valor alto indica aislamiento estructural.

Fórmula por vértice:

$$ASP(v) = \frac{1}{|R(v)|} \sum_{u \in R(v)} d(v, u)$$

donde $R(v)$ son los vértices alcanzables desde v (excluyendo v).

Métrica global:

$$\overline{ASP} = \frac{1}{|V|} \sum_{v \in V} ASP(v)$$

Esta métrica global cuantifica la compacidad de la red entera. El experimento de los *seis grados de separación* corresponde a medir $\overline{ASP}$ en la red social humana.

Complejidad: $O(|V| \cdot (|V| + |E|))$

Aplicación. En Yeast PPI, un $\overline{ASP}$ bajo confirma que la red es compacta (propiedad de *small-world*), lo que facilita la propagación de señales biológicas. En Trade Network, países con bajo ASP individual son los más integrados al sistema de comercio global.

Eigenvector Centrality

Concepto. Extiende el degree ponderando cada vecino por su propia centralidad. Es la base matemática del PageRank [5].

Definición. Sea $\mathbf{A}$ la matriz de adyacencia. El vector $\mathbf{x}$ de Eigenvector Centrality satisface:

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x} \quad \Longleftrightarrow \quad C_E(v) = \frac{1}{\lambda} \sum_{u \in N(v)} C_E(u)$$

donde λ es el autovalor dominante de $\mathbf{A}$ (Perron-Frobenius).

Algoritmo: *Power Iteration*: inicializar $\mathbf{x}^{(0)}$ uniformemente, iterar $\mathbf{x}^{(k+1)} \leftarrow \mathbf{A} \mathbf{x}^{(k)}$ normalizando por el máximo hasta convergencia.

Complejidad: $O(k \cdot (|V| + |E|))$

Diferencia con PageRank. PageRank agrega un factor de amortiguación d y maneja nodos sin salidas. Eigenvector Centrality es la versión pura; ambos coinciden cuando $d \rightarrow 1$ y no hay nodos dangling.

Aplicación. En Yeast PPI, identifica el núcleo funcional: proteínas que interactúan con otras que también son muy conectadas. En Trade Network, captura países cuya influencia comercial se amplifica por sus socios.

Clustering Coefficient

Concepto. Mide qué fracción de los vecinos de un vértice están conectados entre sí. Cuantifica la tendencia a formar grupos locales (*clustering*) [6].

Fórmula local:

$$C_{Cl}(v) = \frac{|\{(u, w) \in E : u, w \in N(v)\}|}{\deg(v)(\deg(v) - 1)}$$

El numerador cuenta los pares de vecinos de v que están conectados (triángulos que pasan por v); el denominador es el máximo posible. El resultado está en $[0, 1]$.

Coefficiente global:

$$\overline{C_{Cl}} = \frac{1}{|V|} \sum_{v \in V} C_{Cl}(v)$$

Complejidad: $O(|V| \cdot \overline{\deg}^2)$, donde $\overline{\deg}$ es el grado promedio.

Aplicación. En Yeast PPI, alto clustering indica la presencia de complejos proteicos: grupos donde todas las proteínas interactúan entre sí (ribosomas, complejos de transcripción). En Trade Network, alto clustering de un país indica que sus socios comerciales también comercian entre sí, formando bloques económicos regionales.

Datasets Seleccionados

Dataset 1: Yeast Protein-Protein Interaction Network

Característica	Valor
Tipo	No dirigido, no ponderado
Vértices	6.526 proteínas
Aristas	532.180 interacciones
Formato	Lista de aristas separada por tabuladores
Fuente	Kaggle / Alexander Chervov

Cada fila representa una interacción entre dos proteínas identificadas por sus nombres sistemáticos (e.g., YLR418C, YOL145C). El archivo lista cada arista en ambas direcciones, por lo que se aplica deduplicación durante la carga.

Las proteínas de *Saccharomyces cerevisiae* son ampliamente usadas como organismo modelo en biología celular. Esta red es un benchmark clásico en análisis de redes biológicas.

Dataset 2: Trade Network

Característica	Valor
Tipo	Dirigido, ponderado
Vértices	≈ 161 países
Aristas	Miles de relaciones comerciales
Peso de arista	Valor del flujo comercial (USD)
Formato	Pajek .net
Años disponibles	2000, 2005, 2010, 2015, 2018

El archivo Pajek contiene una sección ***Vertices** con países y coordenadas, seguida de ***Arcs** con las exportaciones dirigidas y su peso en USD. Una arista $A \rightarrow B$ con peso w indica que el país A exportó w USD al país B .

Para los experimentos se combinan los cinco años en un único grafo, conservando el peso máximo observado para cada par de países. Esto produce la red de comercio internacional más completa del dataset.

Análisis de Complejidad Teórica

Representación: Lista de Adyacencia

Se utiliza una lista de adyacencia implementada con `unordered_map<int, vector<Edge>>`. Esta representación es óptima para redes reales, que son típicamente dispersas ($|E| \ll |V|^2$) [4].

Representación	Memoria	Iterar vecinos	Verificar arista
Lista de adyacencia	$O(V + E)$	$O(\deg(v))$	$O(\deg(v))$
Matriz de adyacencia	$O(V ^2)$	$O(V)$	$O(1)$

Para Yeast con $|V| = 6,526$, una matriz requeriría $6,526^2 \approx 42$ millones de entradas (~ 340 MB), mientras que la lista de adyacencia ocupa ~ 24 MB.

Operaciones sobre el Grafo

Operación	Complejidad
<code>addVertex</code>	$O(1)$ esperado
<code>addEdge</code>	$O(1)$ esperado
<code>removeEdge</code>	$O(\deg(v))$
<code>hasEdge</code>	$O(\deg(v))$
Construcción completa	$O(V + E)$

`addVertex` inserta en `unordered_map` y `addEdge` hace una búsqueda en `unordered_map` más un `push_back` en `vector`. Ambas son $O(1)$ **esperado** (caso promedio con función de hash uniforme), no amortizado en el sentido estricto: en el peor caso con colisiones degeneradas, la complejidad sube a $O(|V|)$.

Complejidad de las Métricas

Métrica	Complejidad	Algoritmo base
Degree Centrality	$O(V + E)$	Recorrido de vecinos
Betweenness Centrality	$O(V \cdot E)$	Brandes (BFS por fuente)
Closeness Centrality	$O(V \cdot (V + E))$	BFS por fuente
PageRank	$O(k \cdot (V + E))$	Iteración de potencias
Average Shortest Path	$O(V \cdot (V + E))$	BFS por fuente
Eigenvector Centrality	$O(k \cdot (V + E))$	Power Iteration
Clustering Coefficient	$O(V \cdot \overline{\deg}^2)$	Conteo de triángulos

donde k es el número de iteraciones hasta convergencia ($k < 100$ en la práctica) y $\overline{\deg}$ es el grado promedio de la red.

Peor caso dominante: Betweenness con $O(|V| \cdot |E|)$. Para Yeast esto implica $6,526 \times 532,180 \approx 3,47 \times 10^9$ operaciones por ejecución, lo que se verá reflejado en los experimentos.

Relación entre Métricas

Las métricas no son independientes. En redes reales existe correlación positiva entre Degree y Eigenvector Centrality (hubs se conectan con hubs), mientras que Betweenness puede identificar vértices con degree moderado pero posición estructural estratégica (puentes entre comunidades). Esta comparación es parte del análisis experimental.

Estudio Experimental

Metodología y Entorno de Pruebas

Los experimentos se ejecutaron en un equipo con sistema operativo Windows 11 Home, compilando con MinGW-w64 GCC 14.x en modo Release (optimización `-O2`). Cada métrica se ejecutó **10 veces consecutivas** sobre el grafo ya construido en memoria, reportando media aritmética, varianza, mínimo y máximo. La medición de tiempo utiliza `std::chrono::high_resolution_clock`.

El código fuente está disponible en: <https://github.com/ricachii/Centralidad-de-Redes>

Construcción del Grafo

Dataset	Tiempo de construcción (ms)	Memoria (KB)
Yeast PPI (6.526V, 532.180E)	3.902	24.150
Trade Network (161V, 22.475E)	551	571

La diferencia de memoria (24 MB vs 571 KB) refleja directamente el tamaño de cada red. Usando lista de adyacencia, Yeast ocupa ~ 24 MB frente a los ~ 340 MB que requeriría una matriz de adyacencia ($6,526^2$ entradas).

Tiempo de Ejecución por Métrica

Dataset 1: Yeast PPI

Métrica	Media (ms)	Varianza (ms^2)	Mín	Máx
Degree Centrality	0,73	0,007	0,641	0,923
PageRank	298	177	290	337
Eigenvector	411	178	404	451
Clustering Coeff.	10.493	341	10.459	10.514
Closeness	60.020	3.365	59.903	60.128
Average Shortest Path	60.042	4.577	59.964	60.158
Betweenness	109.452	87.823	109.039	110.020

Dataset 2: Trade Network

Métrica	Media (ms)	Varianza (ms^2)	Mín	Máx
Degree Centrality	0,025	$1,5 \times 10^{-5}$	0,020	0,032
PageRank	24,9	0,18	24,3	25,7
Eigenvector	34,5	0,049	34,3	34,9
Clustering Coeff.	699	581	666	727
Closeness	705	735	673	739
Average Shortest Path	702	644	672	737
Betweenness	722	1.602	647	786




Figura 1: Tiempos de ejecución por métrica. Izquierda: Yeast PPI. Derecha: Trade Network. Escala logarítmica para visualizar el rango de 6 órdenes de magnitud.

Métricas Adicionales: Eigenvector y Clustering Coefficient

Eigenvector Centrality tardó 411 ms en Yeast (varianza 178 ms^2) y 34,5 ms en Trade (varianza $0,049 \text{ ms}^2$). La baja varianza en ambos datasets confirma que Power Iteration converge de forma predecible en menos de 100 iteraciones. En Yeast, los nodos con alta Eigenvector Centrality corresponden a proteínas que interactúan con otras proteínas también muy conectadas, formando el núcleo funcional de la red. En Trade, identifica países cuya influencia comercial se amplifica a través de sus socios estratégicos.

Clustering Coefficient tardó 10.493 ms en Yeast (varianza 341 ms^2) y 699 ms en Trade (varianza 581 ms^2). La varianza es la más baja de las métricas lentas, producto del comportamiento determinista del conteo de triángulos. En Yeast, el alto coeficiente de clustering global indica la presencia de complejos proteicos: módulos donde todas las proteínas interactúan entre sí (ribosomas, complejos de transcripción). En Trade, países con alto clustering pertenecen a bloques comerciales regionales donde sus socios también comercian entre sí.

Impacto de Modificaciones Estructurales

Se evaluó el impacto de agregar y quitar 5 aristas en tres zonas: nodos *hub* (top 10 % por grado), periféricos (bottom 10 %) y posiciones aleatorias.

Yeast PPI

Op.	Zona	Betweenness	Closeness	ASP
+5	Hub	$-4,3 \times 10^{-5} \%$	$+2,5 \times 10^{-5} \%$	$-2,3 \times 10^{-5} \%$
+5	Periférico	$-0,007 \%$	$+0,003 \%$	$-0,004 \%$
+5	Aleatorio	$-0,001 \%$	$+0,0004 \%$	$-0,0005 \%$
-5	Hub	$+5,0 \times 10^{-5} \%$	$-2,8 \times 10^{-5} \%$	$+2,8 \times 10^{-5} \%$
-5	Periférico	$-0,158 \%$	$-0,060 \%$	$-0,082 \%$
-5	Aleatorio	$-0,053 \%$	$-0,020 \%$	$-0,027 \%$

Trade Network

Op.	Zona	Betweenness	Closeness	ASP
+5	Hub	0 %	0 %	0 %
+5	Periférico	+5,86 %	+0,354 %	+1,135 %
+5	Aleatorio	-0,189 %	+0,013 %	-0,018 %
-5	Hub	+0,189 %	-0,021 %	+0,018 %
-5	Periférico	+0,189 %	-0,010 %	+0,018 %
-5	Aleatorio	+0,189 %	-0,017 %	+0,018 %

Análisis de los Resultados

Betweenness domina en tiempo. En Yeast tardó 109 segundos por ejecución, representando más del 98 % del tiempo total del experimento. Esto confirma la predicción teórica de $O(|V| \cdot |E|) \approx 3,47 \times 10^9$ operaciones. El algoritmo de Brandes es indispensable: sin él, la complejidad naive $O(|V|^2 \cdot |E|)$ haría el cálculo inviable.

Closeness y ASP son equivalentes en tiempo. Ambas realizan BFS desde cada vértice, compartiendo la implementación `bfsDistances()`, lo que se refleja en tiempos casi idénticos (60.020 ms vs 60.042 ms en Yeast).

Diferencia de escala entre datasets. Betweenness en Trade (722 ms) vs Yeast (109.452 ms) — una diferencia de $\sim 150\times$, consistente con la relación entre sus tamaños ($|V| \cdot |E|$: Trade $\approx 3,6 \times 10^6$ vs Yeast $\approx 3,5 \times 10^9$).

Yeast es robusta ante cambios locales. Con 532.180 aristas, agregar o quitar 5 produce variaciones menores al 0,2 % en todas las métricas. Los cambios son mayores en nodos periféricos que en hubs, ya que los hubs ya disponen de múltiples caminos alternativos.

Trade es sensible en su periferia. Agregar 5 aristas desde nodos periféricos aumenta Betweenness un 5,86 %, pues crea caminos mínimos nuevos que reorganizan el flujo global. Los hubs, en cambio, muestran 0 % de cambio al agregar aristas: con densidad $\approx 87\%$, ya no existen pares sin conexión entre los nodos más conectados.

Conclusiones

Este proyecto implementó un sistema completo de análisis de redes en C++17, cubriendo siete métricas de centralidad aplicadas a dos redes reales con características contrastantes: una red biológica dispersa y de gran escala, y una red económica densa y pequeña.

Los experimentos confirman que **la representación importa**: la lista de adyacencia permite analizar Yeast con 24 MB frente a los 340 MB de una matriz, diferencia determinante para la factibilidad del análisis.

Betweenness es el cuello de botella computacional. Su complejidad $O(|V| \cdot |E|)$ implica 109 segundos por ejecución en Yeast. El algoritmo de Brandes es la única razón por la que este cálculo es viable; sin él tomaría días. En contraste, PageRank y Eigenvector convergen en menos de 100 iteraciones, siendo eficientes incluso en la red más grande.

El experimento de aristas revela una diferencia estructural fundamental: **Yeast es robusta** (alta densidad, cambios mínimos ante perturbaciones), mientras que **Trade es sensible en su periferia** (nodos poco conectados amplifican el impacto de cada arista nueva). En términos aplicados, esto sugiere que en el comercio internacional, integrar economías periféricas tiene mayor impacto estructural que reforzar vínculos entre potencias ya conectadas.

Las métricas adicionales aportan dimensiones complementarias: Eigenvector Centrality captura la *influencia propagada* (estar conectado a nodos importantes) y Clustering Coefficient mide la *cohesión local* (formación de grupos o módulos). Juntas con las

cinco métricas base, ofrecen una visión multidimensional de la importancia de cada nodo que ninguna métrica individual puede proporcionar por sí sola.

Referencias

- [1] U. Brandes, “A faster algorithm for betweenness centrality,” *Journal of Mathematical Sociology*, vol. 25, no. 2, pp. 163–177, 2001.
<https://doi.org/10.1080/0022250X.2001.9990249>
- [2] L. Page, S. Brin, R. Motwani, T. Winograd, “The PageRank Citation Ranking: Bringing Order to the Web,” *Stanford InfoLab Technical Report*, 1999.
<https://www.cis.upenn.edu/~mkearns/teaching/NetworkedLife/pagerank.pdf>
- [3] S. Wasserman, K. Faust, *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.
- [4] T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, 3rd ed. MIT Press, 2009.
- [5] P. Bonacich, “Power and Centrality: A Family of Measures,” *American Journal of Sociology*, vol. 92, no. 5, pp. 1170–1182, 1987.
https://web.archive.org/web/20210729125432id_/http://www.leonidzhukov.net/hse/2014/socialnetworks/papers/Bonacich-Centrality.pdf
- [6] D. J. Watts, S. H. Strogatz, “Collective dynamics of ‘small-world’ networks,” *Nature*, vol. 393, pp. 440–442, 1998.
<https://snap.stanford.edu/class/cs224w-readings/watts98smallworld.pdf>