

Universidad — Ingeniería en Computación

Estructuras de Datos

Entrega Parcial

Métricas de Centralidad en Redes

Integrante 1: Nicolás Ricciardi

Integrante 2: Enzo Levancini

Integrante 3: Máximo Beltrán

Junio 2026

Índice

1. Introducción	2
2. Métricas de Centralidad	2
2.1. Degree Centrality	2
2.2. Betweenness Centrality	2
2.3. Closeness Centrality	3
2.4. PageRank	3
2.5. Average Shortest Path	4
2.6. Eigenvector Centrality	4
2.7. Clustering Coefficient	5
3. Datasets Seleccionados	5
3.1. Dataset 1: Yeast Protein-Protein Interaction Network	5
3.2. Dataset 2: Trade Network	6
4. Análisis de Complejidad Teórica	6
4.1. Representación: Lista de Adyacencia	6
4.2. Operaciones sobre el Grafo	6
4.3. Complejidad de las Métricas	7
4.4. Relacion entre Metricas	7

Introducción

Una **red** es una estructura matemática compuesta por un conjunto de **vértices** (nodos) y un conjunto de **aristas** (relaciones entre nodos). Formalmente, un grafo $G = (V, E)$ donde V es el conjunto de vértices y $E \subseteq V \times V$ el de aristas.

Las redes aparecen de forma natural en muchos dominios:

Dominio	Vértice	Arista
Biología	Proteína	Interacción física
Comercio	País	Flujo comercial
Cine	Actor	Aparición en la misma película
Informática	Dirección IP	Conexión de red

Una pregunta central en el análisis de redes es: *¿cuál elemento es el más “importante”?* La respuesta depende de qué se entiende por importancia. Las **métricas de centralidad** responden esta pregunta desde distintos ángulos, cada una capturando una noción diferente de relevancia estructural.

En este proyecto se implementan **siete métricas de centralidad**, aplicadas sobre dos redes reales: la red de interacciones proteína-proteína de levadura (*Yeast PPI*) y la red de comercio internacional (*Trade Network*).

Métricas de Centralidad

Degree Centrality

Concepto. Un vértice es importante si tiene muchas conexiones directas. Es la métrica más simple y sirve como referencia para comparar con las demás.

Fórmula (grafo no dirigido, normalizada):

$$C_D(v) = \frac{\deg(v)}{n-1}$$

donde $\deg(v)$ es el número de vecinos directos de v y $n = |V|$.

En grafos **dirigidos** se distingue in-degree (aristas entrantes, popularidad) y out-degree (aristas salientes, actividad).

Complejidad: $O(|V| + |E|)$

Aplicación. En la red Yeast PPI, una proteína con alto degree es un *hub* biológico cuya eliminación puede resultar letal para el organismo. En Trade Network, el in-degree refleja diversificación de importaciones y el out-degree el alcance exportador de un país.

Betweenness Centrality

Concepto. Un vértice es importante si actúa como puente en los caminos más cortos entre otros pares. Captura el control sobre el flujo en la red.

Fórmula:

$$C_B(v) = \sum_{\substack{s \neq v \neq t \\ s \neq t}} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

donde σ_{st} es el número total de caminos más cortos entre s y t , y $\sigma_{st}(v)$ los que pasan por v .

Normalización:

$$C_B^{\text{norm}}(v) = \begin{cases} \frac{C_B(v)}{(n-1)(n-2)} & \text{dirigido} \\ \frac{2C_B(v)}{(n-1)(n-2)} & \text{no dirigido} \end{cases}$$

Algoritmo: Brandes [1], que calcula la betweenness exacta para todos los vértices con un BFS por vértice fuente.

Complejidad: $O(|V| \cdot |E|)$

Aplicación. En Yeast PPI, alta betweenness indica proteínas que conectan módulos funcionales distintos; su eliminación puede desconectar regiones de la red. En Trade Network, identifica países que actúan como intermediarios críticos del comercio global.

Closeness Centrality

Concepto. Un vértice es importante si puede alcanzar rápidamente a todos los demás. Se basa en la inversa de la distancia promedio.

Fórmula (Wasserman & Faust [3], para grafos desconectados):

$$C_C(v) = \frac{n-1}{N-1} \cdot \frac{n-1}{\sum_{u \neq v} d(v, u)}$$

donde n es el número de vértices alcanzables desde v , $N = |V|$ el total, y $d(v, u)$ la distancia mínima entre v y u .

El factor $\frac{n-1}{N-1}$ penaliza vértices que no alcanzan al resto, permitiendo comparar en grafos desconectados.

Complejidad: $O(|V| \cdot (|V| + |E|))$ via BFS desde cada vértice.

Aplicación. En Yeast PPI, alta closeness indica proteínas con rol regulatorio global, capaces de transmitir señales al resto de la red en pocas interacciones. En Trade Network, países con alta closeness están integrados eficientemente con la economía mundial.

PageRank

Concepto. Un vértice es importante si está conectado a otros vértices importantes. Un enlace desde un nodo de alto PageRank vale más [2].

Fórmula iterativa:

$$PR(v) = \frac{1-d}{n} + d \sum_{u \in N^-(v)} \frac{PR(u)}{|N^+(u)|}$$

donde $d = 0,85$ es el factor de amortiguación (*damping factor*), $N^-(v)$ son los vecinos que apuntan a v , y $N^+(u)$ los destinos de u .

El término $\frac{1-d}{n}$ modela la probabilidad de salto aleatorio a cualquier nodo. El algoritmo itera hasta convergencia ($\|PR^{(k+1)} - PR^{(k)}\|_1 < 10^{-6}$).

Complejidad: $O(k \cdot (|V| + |E|))$, con $k < 100$ en la práctica.

Aplicación. En Trade Network, el PageRank refleja la importancia de un país en el comercio global ponderada por la importancia de sus socios, capturando influencia indirecta que el degree no detecta. En Yeast PPI, identifica proteínas centrales cuya importancia está reforzada por sus vecinas.

Average Shortest Path

Concepto. Promedio de las distancias mínimas desde un vértice hacia todos los demás alcanzables. Un valor alto indica aislamiento estructural.

Fórmula por vértice:

$$ASP(v) = \frac{1}{|R(v)|} \sum_{u \in R(v)} d(v, u)$$

donde $R(v)$ son los vértices alcanzables desde v (excluyendo v).

Métrica global:

$$\overline{ASP} = \frac{1}{|V|} \sum_{v \in V} ASP(v)$$

Esta métrica global cuantifica la compacidad de la red entera. El experimento de los *seis grados de separación* corresponde a medir $\overline{ASP}$ en la red social humana.

Complejidad: $O(|V| \cdot (|V| + |E|))$

Aplicación. En Yeast PPI, un $\overline{ASP}$ bajo confirma que la red es compacta (propiedad de *small-world*), lo que facilita la propagación de señales biológicas. En Trade Network, países con bajo ASP individual son los más integrados al sistema de comercio global.

Eigenvector Centrality

Concepto. Extiende el degree ponderando cada vecino por su propia centralidad. Es la base matemática del PageRank [5].

Definición. Sea $\mathbf{A}$ la matriz de adyacencia. El vector $\mathbf{x}$ de Eigenvector Centrality satisface:

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x} \quad \Longleftrightarrow \quad C_E(v) = \frac{1}{\lambda} \sum_{u \in N(v)} C_E(u)$$

donde λ es el autovalor dominante de $\mathbf{A}$ (Perron-Frobenius).

Algoritmo: *Power Iteration*: inicializar $\mathbf{x}^{(0)}$ uniformemente, iterar $\mathbf{x}^{(k+1)} \leftarrow \mathbf{A} \mathbf{x}^{(k)}$ normalizando por el máximo hasta convergencia.

Complejidad: $O(k \cdot (|V| + |E|))$

Diferencia con PageRank. PageRank agrega un factor de amortiguación d y maneja nodos sin salidas. Eigenvector Centrality es la versión pura; ambos coinciden cuando $d \rightarrow 1$ y no hay nodos dangling.

Aplicación. En Yeast PPI, identifica el núcleo funcional: proteínas que interactúan con otras que también son muy conectadas. En Trade Network, captura países cuya influencia comercial se amplifica por sus socios.

Clustering Coefficient

Concepto. Mide qué fracción de los vecinos de un vértice están conectados entre sí. Cuantifica la tendencia a formar grupos locales (*clustering*) [6].

Fórmula local:

$$C_{Cl}(v) = \frac{|\{(u, w) \in E : u, w \in N(v)\}|}{\deg(v)(\deg(v) - 1)}$$

El numerador cuenta los pares de vecinos de v que están conectados (triángulos que pasan por v); el denominador es el máximo posible. El resultado está en $[0, 1]$.

Coefficiente global:

$$\overline{C_{Cl}} = \frac{1}{|V|} \sum_{v \in V} C_{Cl}(v)$$

Complejidad: $O(|V| \cdot \overline{\deg}^2)$, donde $\overline{\deg}$ es el grado promedio.

Aplicación. En Yeast PPI, alto clustering indica la presencia de complejos proteicos: grupos donde todas las proteínas interactúan entre sí (ribosomas, complejos de transcripción). En Trade Network, alto clustering de un país indica que sus socios comerciales también comercian entre sí, formando bloques económicos regionales.

Datasets Seleccionados

Dataset 1: Yeast Protein-Protein Interaction Network

Característica	Valor
Tipo	No dirigido, no ponderado
Vértices	6.526 proteínas
Aristas	532.180 interacciones
Formato	Lista de aristas separada por tabuladores
Fuente	Kaggle / Alexander Chervov

Cada fila representa una interacción entre dos proteínas identificadas por sus nombres sistemáticos (e.g., YLR418C, YOL145C). El archivo lista cada arista en ambas direcciones, por lo que se aplica deduplicación durante la carga.

Las proteínas de *Saccharomyces cerevisiae* son ampliamente usadas como organismo modelo en biología celular. Esta red es un benchmark clásico en análisis de redes biológicas.

Dataset 2: Trade Network

Característica	Valor
Tipo	Dirigido, ponderado
Vértices	≈ 161 países
Aristas	Miles de relaciones comerciales
Peso de arista	Valor del flujo comercial (USD)
Formato	Pajek .net
Años disponibles	2000, 2005, 2010, 2015, 2018

El archivo Pajek contiene una sección ***Vertices** con países y coordenadas, seguida de ***Arcs** con las exportaciones dirigidas y su peso en USD. Una arista $A \rightarrow B$ con peso w indica que el país A exportó w USD al país B .

Para los experimentos se combinan los cinco años en un único grafo, conservando el peso máximo observado para cada par de países. Esto produce la red de comercio internacional más completa del dataset.

Análisis de Complejidad Teórica

Representación: Lista de Adyacencia

Se utiliza una lista de adyacencia implementada con `unordered_map<int, vector<Edge>>`. Esta representación es óptima para redes reales, que son típicamente dispersas ($|E| \ll |V|^2$) [4].

Representación	Memoria	Iterar vecinos	Verificar arista
Lista de adyacencia	$O(V + E)$	$O(\deg(v))$	$O(\deg(v))$
Matriz de adyacencia	$O(V ^2)$	$O(V)$	$O(1)$

Para Yeast con $|V| = 6,526$, una matriz requeriría $6,526^2 \approx 42$ millones de entradas (~ 340 MB), mientras que la lista de adyacencia ocupa ~ 24 MB.

Operaciones sobre el Grafo

Operación	Complejidad
<code>addVertex</code>	$O(1)$ esperado
<code>addEdge</code>	$O(1)$ esperado
<code>removeEdge</code>	$O(\deg(v))$
<code>hasEdge</code>	$O(\deg(v))$
Construcción completa	$O(V + E)$

`addVertex` inserta en `unordered_map` y `addEdge` hace una búsqueda en `unordered_map` más un `push_back` en `vector`. Ambas son $O(1)$ **esperado** (caso promedio con función de hash uniforme), no amortizado en el sentido estricto: en el peor caso con colisiones degeneradas, la complejidad sube a $O(|V|)$.

Complejidad de las Métricas

Métrica	Complejidad	Algoritmo base
Degree Centrality	$O(V + E)$	Recorrido de vecinos
Betweenness Centrality	$O(V \cdot E)$	Brandes (BFS por fuente)
Closeness Centrality	$O(V \cdot (V + E))$	BFS por fuente
PageRank	$O(k \cdot (V + E))$	Iteración de potencias
Average Shortest Path	$O(V \cdot (V + E))$	BFS por fuente
Eigenvector Centrality	$O(k \cdot (V + E))$	Power Iteration
Clustering Coefficient	$O(V \cdot \overline{\deg}^2)$	Conteo de triángulos

donde k es el número de iteraciones hasta convergencia ($k < 100$ en la práctica) y $\overline{\deg}$ es el grado promedio de la red.

Peor caso dominante: Betweenness con $O(|V| \cdot |E|)$. Para Yeast esto implica $6,526 \times 532,180 \approx 3,47 \times 10^9$ operaciones por ejecución, lo que se verá reflejado en los experimentos.

Relación entre Métricas

Las métricas no son independientes. En redes reales existe correlación positiva entre Degree y Eigenvector Centrality (hubs se conectan con hubs), mientras que Betweenness puede identificar vértices con degree moderado pero posición estructural estratégica (puentes entre comunidades). Esta comparación es parte del análisis experimental.

Referencias

- [1] U. Brandes, “A faster algorithm for betweenness centrality,” *Journal of Mathematical Sociology*, vol. 25, no. 2, pp. 163–177, 2001.
<https://doi.org/10.1080/0022250X.2001.9990249>
- [2] L. Page, S. Brin, R. Motwani, T. Winograd, “The PageRank Citation Ranking: Bringing Order to the Web,” *Stanford InfoLab Technical Report*, 1999.
<https://www.cis.upenn.edu/~mkearns/teaching/NetworkedLife/pagerank.pdf>
- [3] S. Wasserman, K. Faust, *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.
- [4] T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, 3rd ed. MIT Press, 2009.

- [5] P. Bonacich, “Power and Centrality: A Family of Measures,” *American Journal of Sociology*, vol. 92, no. 5, pp. 1170–1182, 1987.
https://web.archive.org/web/20210729125432id_/http://www.leonidzhukov.net/hse/2014/socialnetworks/papers/Bonacich-Centrality.pdf
- [6] D. J. Watts, S. H. Strogatz, “Collective dynamics of ‘small-world’ networks,” *Nature*, vol. 393, pp. 440–442, 1998.
<https://snap.stanford.edu/class/cs224w-readings/watts98smallworld.pdf>