



Universidad de Concepción

Facultad de Ingeniería

Departamento de Ing. Informática y Ciencias de la Computación

Ingeniería Civil Informática

Estructuras de Datos

Métricas de Centralidad en Redes

Entrega Final

Integrantes:

Nicolás Ricciardi

Enzo Levancini

Máximo Beltrán

Junio 2026

Índice

1. Introducción	3
2. Métricas de Centralidad	3
2.1. Degree Centrality	3
2.2. Betweenness Centrality	3
2.3. Closeness Centrality	4
2.4. PageRank	4
2.5. Average Shortest Path	5
2.6. Eigenvector Centrality	5
2.7. Clustering Coefficient	6
3. Ejemplo Explicativo: Cálculo Paso a Paso	6
3.1. Degree Centrality	6
3.2. Closeness Centrality	7
3.3. Betweenness Centrality	7
3.4. Clustering Coefficient	8
3.5. Conclusión del Ejemplo	8
4. Datasets Seleccionados	8
4.1. Dataset 1: Yeast Protein-Protein Interaction Network	8
4.2. Dataset 2: Trade Network	9
4.3. Alcance: Análisis sobre la Topología no Ponderada	9
5. Análisis de Complejidad Teórica	10
5.1. Representación: Lista de Adyacencia	10
5.2. Operaciones sobre el Grafo	10
5.3. Complejidad de las Métricas	10
5.4. Relación entre Métricas	11
6. Estudio Experimental	11
6.1. Metodología y Entorno de Pruebas	11
6.2. Construcción del Grafo	11
6.3. Tiempo de Ejecución por Métrica	12
6.4. Métricas Adicionales: Eigenvector y Clustering Coefficient	12

6.5. Impacto de Modificaciones Estructurales	13
6.6. Impacto sobre las Métricas Adicionales	13
7. Conclusiones	15

Introducción

Una **red** es una estructura matemática compuesta por un conjunto de **vértices** (nodos) y un conjunto de **aristas** (relaciones entre nodos). Formalmente, un grafo $G = (V, E)$ donde V es el conjunto de vértices y $E \subseteq V \times V$ el de aristas.

Las redes aparecen de forma natural en muchos dominios:

Dominio	Vértice	Arista
Biología	Proteína	Interacción física
Comercio	País	Flujo comercial
Cine	Actor	Aparición en la misma película
Informática	Dirección IP	Conexión de red

Una pregunta central en el análisis de redes es: *¿cuál elemento es el más “importante”?* La respuesta depende de qué se entiende por importancia. Las **métricas de centralidad** responden esta pregunta desde distintos ángulos, cada una capturando una noción diferente de relevancia estructural.

En este proyecto se implementan **siete métricas de centralidad**, aplicadas sobre dos redes reales: la red de interacciones proteína-proteína de levadura (*Yeast PPI*) y la red de comercio internacional (*Trade Network*).

Métricas de Centralidad

Degree Centrality

Concepto. Un vértice es importante si tiene muchas conexiones directas. Es la métrica más simple y sirve como referencia para comparar con las demás.

Fórmula (grafo no dirigido, normalizada):

$$C_D(v) = \frac{\deg(v)}{n-1}$$

donde $\deg(v)$ es el número de vecinos directos de v y $n = |V|$.

En grafos **dirigidos** se distingue in-degree (aristas entrantes, popularidad) y out-degree (aristas salientes, actividad).

Complejidad: $O(|V| + |E|)$

Aplicación. En la red Yeast PPI, una proteína con alto degree es un *hub* biológico cuya eliminación puede resultar letal para el organismo. En Trade Network, el in-degree refleja diversificación de importaciones y el out-degree el alcance exportador de un país.

Betweenness Centrality

Concepto. Un vértice es importante si actúa como puente en los caminos más cortos entre otros pares. Captura el control sobre el flujo en la red.

Fórmula:

$$C_B(v) = \sum_{\substack{s \neq v \neq t \\ s \neq t}} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

donde σ_{st} es el número total de caminos más cortos entre s y t , y $\sigma_{st}(v)$ los que pasan por v .

Normalización:

$$C_B^{\text{norm}}(v) = \begin{cases} \frac{C_B(v)}{(n-1)(n-2)} & \text{dirigido} \\ \frac{2C_B(v)}{(n-1)(n-2)} & \text{no dirigido} \end{cases}$$

Algoritmo: Brandes [1], que calcula la betweenness exacta para todos los vértices con un BFS por vértice fuente.

Complejidad: $O(|V| \cdot |E|)$

Aplicación. En Yeast PPI, alta betweenness indica proteínas que conectan módulos funcionales distintos; su eliminación puede desconectar regiones de la red. En Trade Network, identifica países que actúan como intermediarios críticos del comercio global.

Closeness Centrality

Concepto. Un vértice es importante si puede alcanzar rápidamente a todos los demás. Se basa en la inversa de la distancia promedio.

Fórmula (Wasserman & Faust [3], para grafos desconectados):

$$C_C(v) = \frac{n-1}{N-1} \cdot \frac{n-1}{\sum_{u \neq v} d(v, u)}$$

donde n es el número de vértices alcanzables desde v , $N = |V|$ el total, y $d(v, u)$ la distancia mínima entre v y u .

El factor $\frac{n-1}{N-1}$ penaliza vértices que no alcanzan al resto, permitiendo comparar en grafos desconectados.

Complejidad: $O(|V| \cdot (|V| + |E|))$ via BFS desde cada vértice.

Aplicación. En Yeast PPI, alta closeness indica proteínas con rol regulatorio global, capaces de transmitir señales al resto de la red en pocas interacciones. En Trade Network, países con alta closeness están integrados eficientemente con la economía mundial.

PageRank

Concepto. Un vértice es importante si está conectado a otros vértices importantes. Un enlace desde un nodo de alto PageRank vale más [2].

Fórmula iterativa:

$$PR(v) = \frac{1-d}{n} + d \sum_{u \in N^-(v)} \frac{PR(u)}{|N^+(u)|}$$

donde $d = 0,85$ es el factor de amortiguación (*damping factor*), $N^-(v)$ son los vecinos que apuntan a v , y $N^+(u)$ los destinos de u .

El término $\frac{1-d}{n}$ modela la probabilidad de salto aleatorio a cualquier nodo. El algoritmo itera hasta convergencia ($\|PR^{(k+1)} - PR^{(k)}\|_1 < 10^{-6}$).

Complejidad: $O(k \cdot (|V| + |E|))$, con $k < 100$ en la práctica.

Aplicación. En Trade Network, el PageRank refleja la importancia de un país en el comercio global ponderada por la importancia de sus socios, capturando influencia indirecta que el degree no detecta. En Yeast PPI, identifica proteínas centrales cuya importancia está reforzada por sus vecinas.

Average Shortest Path

Concepto. Promedio de las distancias mínimas desde un vértice hacia todos los demás alcanzables. Un valor alto indica aislamiento estructural.

Fórmula por vértice:

$$ASP(v) = \frac{1}{|R(v)|} \sum_{u \in R(v)} d(v, u)$$

donde $R(v)$ son los vértices alcanzables desde v (excluyendo v).

Métrica global:

$$\overline{ASP} = \frac{1}{|V|} \sum_{v \in V} ASP(v)$$

Esta métrica global cuantifica la compacidad de la red entera. El experimento de los *seis grados de separación* corresponde a medir $\overline{ASP}$ en la red social humana.

Complejidad: $O(|V| \cdot (|V| + |E|))$

Aplicación. En Yeast PPI, un $\overline{ASP}$ bajo confirma que la red es compacta (propiedad de *small-world*), lo que facilita la propagación de señales biológicas. En Trade Network, países con bajo ASP individual son los más integrados al sistema de comercio global.

Eigenvector Centrality

Concepto. Extiende el degree ponderando cada vecino por su propia centralidad. Es la base matemática del PageRank [5].

Definición. Sea $\mathbf{A}$ la matriz de adyacencia. El vector $\mathbf{x}$ de Eigenvector Centrality satisface:

$$\mathbf{A} \mathbf{x} = \lambda \mathbf{x} \quad \Longleftrightarrow \quad C_E(v) = \frac{1}{\lambda} \sum_{u \in N(v)} C_E(u)$$

donde λ es el autovalor dominante de $\mathbf{A}$ (Perron-Frobenius).

Algoritmo: *Power Iteration*: inicializar $\mathbf{x}^{(0)}$ uniformemente, iterar $\mathbf{x}^{(k+1)} \leftarrow \mathbf{A} \mathbf{x}^{(k)}$ normalizando por el máximo hasta convergencia.

Complejidad: $O(k \cdot (|V| + |E|))$

Diferencia con PageRank. PageRank agrega un factor de amortiguación d y maneja nodos sin salidas. Eigenvector Centrality es la versión pura; ambos coinciden cuando $d \rightarrow 1$ y no hay nodos dangling.

Aplicación. En Yeast PPI, identifica el núcleo funcional: proteínas que interactúan con otras que también son muy conectadas. En Trade Network, captura países cuya influencia comercial se amplifica por sus socios.

Clustering Coefficient

Concepto. Mide qué fracción de los vecinos de un vértice están conectados entre sí. Cuantifica la tendencia a formar grupos locales (*clustering*) [6].

Fórmula local:

$$C_{Cl}(v) = \frac{|\{(u, w) \in E : u, w \in N(v)\}|}{\deg(v)(\deg(v) - 1)}$$

El numerador cuenta los pares de vecinos de v que están conectados (triángulos que pasan por v); el denominador es el máximo posible. El resultado está en $[0, 1]$.

Coefficiente global:

$$\overline{C_{Cl}} = \frac{1}{|V|} \sum_{v \in V} C_{Cl}(v)$$

Complejidad: $O(|V| \cdot \overline{\deg}^2)$, donde $\overline{\deg}$ es el grado promedio.

Aplicación. En Yeast PPI, alto clustering indica la presencia de complejos proteicos: grupos donde todas las proteínas interactúan entre sí (ribosomas, complejos de transcripción). En Trade Network, alto clustering de un país indica que sus socios comerciales también comercian entre sí, formando bloques económicos regionales.

Ejemplo Explicativo: Cálculo Paso a Paso

Para ilustrar el funcionamiento de las métricas, se aplican sobre un grafo pequeño no dirigido de 5 vértices. Esto permite verificar manualmente los resultados que produce la implementación.

Se desarrollan paso a paso las cuatro métricas que admiten un cálculo exacto y directo a mano: Degree, Closeness, Betweenness y Clustering. PageRank y Eigenvector Centrality se omiten en este ejemplo por ser algoritmos iterativos: sus valores convergen tras decenas de iteraciones, por lo que un cálculo manual solo arrojaría aproximaciones. Las siete métricas sí se evalúan de forma completa en la sección experimental.

Degree Centrality

Se cuentan los vecinos directos de cada vértice y se normaliza dividiendo por $n - 1 = 4$:




Figura 1: Grafo de ejemplo. Un triángulo $\{A, B, C\}$ conectado mediante C a un camino $C-D-E$. Aristas: $\{A-B, A-C, B-C, C-D, D-E\}$.

Vértice	A	B	C	D	E
Grado $\deg(v)$	2	2	3	2	1
$C_D(v) = \deg(v)/4$	0,50	0,50	0,75	0,50	0,25

C es el vértice de mayor grado: concentra 3 de las 5 aristas.

Closeness Centrality

Primero se calculan las distancias mínimas (vía BFS) desde cada vértice al resto. Luego $C_C(v) = (n - 1) / \sum_u d(v, u)$, con $n - 1 = 4$:

Desde	a A	a B	a C	a D	a E	$\sum d$	$C_C(v)$
A	—	1	1	2	3	7	0,571
B	1	—	1	2	3	7	0,571
C	1	1	—	1	2	5	0,800
D	2	2	1	—	1	6	0,667
E	3	3	2	1	—	9	0,444

C es el más cercano a todos (distancia total 5), mientras que **E**, en el extremo del camino, es el más aislado (distancia total 9).

Betweenness Centrality

Se enumeran los caminos más cortos entre cada par de vértices y se cuenta por cuáles vértices intermedios pasan. Solo los pares cuyo camino mínimo atraviesa un tercer vértice contribuyen:

Par	Camino más corto	Intermedios
A-D	A-C-D	C
A-E	A-C-D-E	C, D
B-D	B-C-D	C
B-E	B-C-D-E	C, D
C-E	C-D-E	D

Contando las apariciones como vértice intermedio:

Vértice	A	B	C	D	E
$C_B(v)$ (sin normalizar)	0	0	4	3	0

Este es el resultado más interesante: **D** tiene grado bajo (solo 2), pero una betweenness alta (3), porque es el *único* puente hacia E. Esto muestra que betweenness captura algo distinto al degree: la posición estructural, no la cantidad de conexiones.

Clustering Coefficient

Para cada vértice se mide qué fracción de sus pares de vecinos están conectados entre sí:

Vértice	Vecinos	Pares conectados / total	$C_{Cl}(v)$
A	$\{B, C\}$	1/1 (B–C existe)	1,00
B	$\{A, C\}$	1/1 (A–C existe)	1,00
C	$\{A, B, D\}$	1/3 (solo A–B)	0,33
D	$\{C, E\}$	0/1 (C–E no existe)	0,00
E	$\{D\}$	— (grado 1)	0,00

A y **B** tienen clustering máximo: pertenecen al triángulo cerrado $\{A, B, C\}$. En cambio **D**, pese a estar bien posicionado (alta betweenness), no forma ningún triángulo.

Conclusión del Ejemplo

Cada métrica responde una pregunta distinta sobre el mismo grafo: **C** domina en degree y closeness (es el centro), **C** y **D** dominan en betweenness (son los puentes), y **A**, **B** ganan en clustering (forman comunidad). Ningún vértice lidera en todas, lo que confirma que las métricas son complementarias y no redundantes.

Datasets Seleccionados

Dataset 1: Yeast Protein-Protein Interaction Network

Característica	Valor
Tipo	No dirigido, no ponderado
Vértices	6.526 proteínas
Aristas	532.180 interacciones
Formato	Lista de aristas separada por tabuladores
Fuente	Kaggle / Alexander Chervov

Cada fila representa una interacción entre dos proteínas identificadas por sus nombres sistemáticos (e.g., YLR418C, YOL145C). El archivo lista cada arista en ambas direcciones, por lo que se aplica deduplicación durante la carga.

Las proteínas de *Saccharomyces cerevisiae* son ampliamente usadas como organismo modelo en biología celular. Esta red es un benchmark clásico en análisis de redes biológicas.

Dataset 2: Trade Network

Característica	Valor
Tipo	Dirigido, ponderado
Vértices	≈ 161 países
Aristas	Miles de relaciones comerciales
Peso de arista	Valor del flujo comercial (USD)
Formato	Pajek <code>.net</code>
Años disponibles	2000, 2005, 2010, 2015, 2018

El archivo Pajek contiene una sección `*Vertices` con países y coordenadas, seguida de `*Arcs` con las exportaciones dirigidas y su peso en USD. Una arista $A \rightarrow B$ con peso w indica que el país A exportó w USD al país B .

Para los experimentos se combinan los cinco años en un único grafo, conservando el peso máximo observado para cada par de países. Esto produce la red de comercio internacional más completa del dataset.

Alcance: Análisis sobre la Topología no Ponderada

Si bien el ADT Grafo almacena el peso de cada arista (y Trade Network es una red ponderada), las siete métricas implementadas operan sobre la **topología** de la red: su estructura de conexiones, sin considerar el peso. Las métricas basadas en caminos (Betweenness, Closeness y Average Shortest Path) miden distancias en número de aristas mediante BFS, y PageRank y Eigenvector reparten la influencia en partes iguales entre los vecinos.

Esta es la formulación clásica y más difundida de las medidas de centralidad, y se adopta por dos razones. Primero, permite una comparación homogénea entre el dataset ponderado (Trade) y el no ponderado (Yeast), evaluando ambas redes bajo el mismo criterio estructural. Segundo, la dirección de las aristas *sí* se respeta en Trade (grafo dirigido), de modo que se captura la asimetría exportador–importador, que es la característica estructural más relevante de esa red. La extensión a versiones ponderadas —reemplazando BFS por Dijkstra y ponderando el reparto de PageRank por el valor comercial— queda planteada como trabajo futuro.

Análisis de Complejidad Teórica

Representación: Lista de Adyacencia

Se utiliza una lista de adyacencia implementada con `unordered_map<int, vector<Edge>`. Esta representación es óptima para redes reales, que son típicamente dispersas ($|E| \ll |V|^2$) [4].

Representación	Memoria	Iterar vecinos	Verificar arista
Lista de adyacencia	$O(V + E)$	$O(\deg(v))$	$O(\deg(v))$
Matriz de adyacencia	$O(V ^2)$	$O(V)$	$O(1)$

Para Yeast con $|V| = 6,526$, una matriz requeriría $6,526^2 \approx 42$ millones de entradas (~ 340 MB), mientras que la lista de adyacencia ocupa ~ 24 MB.

Operaciones sobre el Grafo

Operación	Complejidad
<code>addVertex</code>	$O(1)$ esperado
<code>addEdge</code>	$O(1)$ esperado
<code>removeEdge</code>	$O(\deg(v))$
<code>hasEdge</code>	$O(\deg(v))$
Construcción completa	$O(V + E)$

`addVertex` inserta en `unordered_map` y `addEdge` hace una búsqueda en `unordered_map` más un `push_back` en `vector`. Ambas son $O(1)$ **esperado** (caso promedio con función de hash uniforme), no amortizado en el sentido estricto: en el peor caso con colisiones degeneradas, la complejidad sube a $O(|V|)$.

Complejidad de las Métricas

Métrica	Tiempo	Espacio	Algoritmo base
Degree Centrality	$O(V + E)$	$O(V)$	Recorrido de vecinos
Betweenness Centrality	$O(V \cdot E)$	$O(V + E)$	Brandes (BFS por fuente)
Closeness Centrality	$O(V \cdot (V + E))$	$O(V)$	BFS por fuente
PageRank	$O(k \cdot (V + E))$	$O(V)$	Iteración de potencias
Average Shortest Path	$O(V \cdot (V + E))$	$O(V)$	BFS por fuente
Eigenvector Centrality	$O(k \cdot (V + E))$	$O(V)$	Power Iteration
Clustering Coefficient	$O(V \cdot \overline{\deg}^2)$	$O(V)$	Conteo de triángulos

donde k es el número de iteraciones hasta convergencia ($k < 100$ en la práctica) y $\overline{\deg}$ es el grado promedio de la red.

Peor caso dominante en tiempo: Betweenness con $O(|V| \cdot |E|)$. Para Yeast esto implica $6,526 \times 532,180 \approx 3,47 \times 10^9$ operaciones por ejecución, lo que se verá reflejado en los experimentos.

Análisis de espacio. Las siete métricas almacenan un resultado de un valor por vértice, lo que aporta un costo base de $O(|V|)$. La mayoría no requiere memoria auxiliar adicional más allá de las estructuras temporales de un BFS (un mapa de distancias de tamaño $O(|V|)$ que se reutiliza por fuente) o de los dos vectores que PageRank y Eigenvector intercambian con **swap** en cada iteración. La excepción es **Betweenness**: el algoritmo de Brandes mantiene, durante cada BFS, listas de predecesores y una pila de vértices que en el peor caso alcanzan $O(|V| + |E|)$. Todas ellas son dominadas por el costo del grafo en sí ($O(|V| + |E|)$), de modo que ninguna métrica incrementa el orden de espacio total del programa.

Relación entre Métricas

Las métricas no son independientes. En redes reales existe correlación positiva entre Degree y Eigenvector Centrality (hubs se conectan con hubs), mientras que Betweenness puede identificar vértices con degree moderado pero posición estructural estratégica (puentes entre comunidades). Esta comparación es parte del análisis experimental.

Estudio Experimental

Metodología y Entorno de Pruebas

Los experimentos se ejecutaron en un equipo con sistema operativo Windows 11 Home, compilando con MinGW-w64 GCC 14.x en modo Release (optimización -O2). Cada métrica se ejecutó **10 veces consecutivas** sobre el grafo ya construido en memoria, reportando media aritmética, varianza, mínimo y máximo. La medición de tiempo utiliza `std::chrono::high_resolution_clock`.

El código fuente está disponible en: <https://github.com/ricachii/Centralidad-de-Redes>

Construcción del Grafo

Dataset	Tiempo de construcción (ms)	Memoria (KB)
Yeast PPI (6.526V, 532.180E)	3.902	24.150
Trade Network (161V, 22.475E)	551	571

La diferencia de memoria (24 MB vs 571 KB) refleja directamente el tamaño de cada red. Usando lista de adyacencia, Yeast ocupa ~ 24 MB frente a los ~ 340 MB que requeriría una matriz de adyacencia ($6,526^2$ entradas).

Tiempo de Ejecución por Métrica

Dataset 1: Yeast PPI

Métrica	Media (ms)	Varianza (ms ²)	Mín	Máx
Degree Centrality	0,73	0,007	0,641	0,923
PageRank	298	177	290	337
Eigenvector	411	178	404	451
Clustering Coeff.	10.493	341	10.459	10.514
Closeness	60.020	3.365	59.903	60.128
Average Shortest Path	60.042	4.577	59.964	60.158
Betweenness	109.452	87.823	109.039	110.020

Dataset 2: Trade Network

Métrica	Media (ms)	Varianza (ms ²)	Mín	Máx
Degree Centrality	0,025	$1,5 \times 10^{-5}$	0,020	0,032
PageRank	24,9	0,18	24,3	25,7
Eigenvector	34,5	0,049	34,3	34,9
Clustering Coeff.	699	581	666	727
Closeness	705	735	673	739
Average Shortest Path	702	644	672	737
Betweenness	722	1.602	647	786




Figura 2: Tiempos de ejecución por métrica. Izquierda: Yeast PPI. Derecha: Trade Network. Escala logarítmica para visualizar el rango de 6 órdenes de magnitud.

Métricas Adicionales: Eigenvector y Clustering Coefficient

Eigenvector Centrality tardó 411 ms en Yeast (varianza 178 ms²) y 34,5 ms en Trade (varianza 0,049 ms²). La baja varianza en ambos datasets confirma que Power Iteration converge de forma predecible en menos de 100 iteraciones. En Yeast, los nodos con alta Eigenvector Centrality corresponden a proteínas que interactúan con otras proteínas también muy conectadas, formando el núcleo funcional de la red. En Trade, identifica países cuya influencia comercial se amplifica a través de sus socios estratégicos.

Clustering Coefficient tardó 10.493 ms en Yeast (varianza 341 ms²) y 699 ms en Trade (varianza 581 ms²). La varianza es la más baja de las métricas lentas, producto

del comportamiento determinista del conteo de triángulos. En Yeast, el alto coeficiente de clustering global indica la presencia de complejos proteicos: módulos donde todas las proteínas interactúan entre sí (ribosomas, complejos de transcripción). En Trade, países con alto clustering pertenecen a bloques comerciales regionales donde sus socios también comercian entre sí.

Impacto de Modificaciones Estructurales

Se evaluó el impacto de agregar y quitar 5 aristas en tres zonas: nodos *hub* (top 10 % por grado), periféricos (bottom 10 %) y posiciones aleatorias.

Yeast PPI

Op.	Zona	Betweenness	Closeness	ASP
+5	Hub	$-4,3 \times 10^{-5} \%$	$+2,5 \times 10^{-5} \%$	$-2,3 \times 10^{-5} \%$
+5	Periférico	$-0,007 \%$	$+0,003 \%$	$-0,004 \%$
+5	Aleatorio	$-0,001 \%$	$+0,0004 \%$	$-0,0005 \%$
-5	Hub	$+5,0 \times 10^{-5} \%$	$-2,8 \times 10^{-5} \%$	$+2,8 \times 10^{-5} \%$
-5	Periférico	$-0,158 \%$	$-0,060 \%$	$-0,082 \%$
-5	Aleatorio	$-0,053 \%$	$-0,020 \%$	$-0,027 \%$

Trade Network

Op.	Zona	Betweenness	Closeness	ASP
+5	Hub	0 %	0 %	0 %
+5	Periférico	+5,86 %	+0,354 %	+1,135 %
+5	Aleatorio	-0,189 %	+0,013 %	-0,018 %
-5	Hub	+0,189 %	-0,021 %	+0,018 %
-5	Periférico	+0,189 %	-0,010 %	+0,018 %
-5	Aleatorio	+0,189 %	-0,017 %	+0,018 %

Impacto sobre las Métricas Adicionales

Se repite el experimento de aristas observando ahora las dos métricas adicionales, Eigenvector y Clustering Coefficient, respondiendo las mismas preguntas: ¿cómo cambian al agregar o quitar 5 aristas en cada zona?

Yeast PPI

Op.	Zona	Eigenvector	Clustering
+5	Hub	$+5,6 \times 10^{-4} \%$	$+1,2 \times 10^{-4} \%$
+5	Periférico	$+2,7 \times 10^{-4} \%$	$+0,201 \%$
+5	Aleatorio	$+2,7 \times 10^{-4} \%$	$-8,0 \times 10^{-4} \%$
-5	Hub	$-1,4 \times 10^{-3} \%$	$-3,6 \times 10^{-4} \%$
-5	Periférico	$-2,1 \times 10^{-4} \%$	$+0,042 \%$
-5	Aleatorio	$-5,6 \times 10^{-4} \%$	$+8,7 \times 10^{-4} \%$

Trade Network

Op.	Zona	Eigenvector	Clustering
+5	Hub	0 %	0 %
+5	Periférico	$-0,087 \%$	$+0,014 \%$
+5	Aleatorio	$+0,013 \%$	$-0,002 \%$
-5	Hub	$-0,026 \%$	$-0,037 \%$
-5	Periférico	$-0,021 \%$	$-0,023 \%$
-5	Aleatorio	$-0,022 \%$	$-0,028 \%$

El resultado más notorio es el **Clustering Coefficient en la zona periférica de Yeast**: agregar 5 aristas lo eleva un $+0,201 \%$, el mayor cambio relativo de todo el experimento. Esto tiene sentido: los nodos periféricos tienen pocos vecinos, de modo que una arista nueva que cierre un triángulo entre ellos altera su coeficiente local de forma proporcionalmente grande. Eigenvector, en cambio, es prácticamente insensible a cambios locales en Yeast (cambios del orden de $10^{-4} \%$), porque distribuye la influencia de manera global a través de toda la red. En Trade, ambas métricas reaccionan más (densidad menor), y se repite el patrón de hubs saturados: agregar aristas en la zona hub produce 0 % de cambio al no existir pares sin conectar.

Betweenness domina en tiempo. En Yeast tardó 109 segundos por ejecución, representando más del 98 % del tiempo total del experimento. Esto confirma la predicción teórica de $O(|V| \cdot |E|) \approx 3,47 \times 10^9$ operaciones. El algoritmo de Brandes es indispensable: sin él, la complejidad naive $O(|V|^2 \cdot |E|)$ haría el cálculo inviable.

Closeness y ASP son equivalentes en tiempo. Ambas realizan BFS desde cada vértice, compartiendo la implementación `bfsDistances()`, lo que se refleja en tiempos casi idénticos (60.020 ms vs 60.042 ms en Yeast).

Diferencia de escala entre datasets. Betweenness en Trade (722 ms) vs Yeast (109.452 ms) — una diferencia de $\sim 150\times$, consistente con la relación entre sus tamaños ($|V| \cdot |E|$: Trade $\approx 3,6 \times 10^6$ vs Yeast $\approx 3,5 \times 10^9$).

Yeast es robusta ante cambios locales. Con 532.180 aristas, agregar o quitar 5 produce variaciones menores al 0,2 % en todas las métricas. Los cambios son mayores en nodos periféricos que en hubs, ya que los hubs ya disponen de múltiples caminos alternativos.

Trade es sensible en su periferia. Agregar 5 aristas desde nodos periféricos aumenta Betweenness un 5,86 %, pues crea caminos mínimos nuevos que reorganizan el flujo global. Los hubs, en cambio, muestran 0 % de cambio al agregar aristas: con densidad $\approx 87\%$, ya no existen pares sin conexión entre los nodos más conectados.

Conclusiones

Este proyecto implementó un sistema completo de análisis de redes en C++17, cubriendo siete métricas de centralidad aplicadas a dos redes reales con características contrastantes: una red biológica dispersa y de gran escala, y una red económica densa y pequeña.

Los experimentos confirman que **la representación importa**: la lista de adyacencia permite analizar Yeast con 24 MB frente a los 340 MB de una matriz, diferencia determinante para la factibilidad del análisis.

Betweenness es el cuello de botella computacional. Su complejidad $O(|V| \cdot |E|)$ implica 109 segundos por ejecución en Yeast. El algoritmo de Brandes es la única razón por la que este cálculo es viable; sin él tomaría días. En contraste, PageRank y Eigenvector convergen en menos de 100 iteraciones, siendo eficientes incluso en la red más grande.

El experimento de aristas revela una diferencia estructural fundamental: **Yeast es robusta** (alta densidad, cambios mínimos ante perturbaciones), mientras que **Trade es sensible en su periferia** (nodos poco conectados amplifican el impacto de cada arista nueva). En términos aplicados, esto sugiere que en el comercio internacional, integrar economías periféricas tiene mayor impacto estructural que reforzar vínculos entre potencias ya conectadas.

Las métricas adicionales aportan dimensiones complementarias: Eigenvector Centrality captura la *influencia propagada* (estar conectado a nodos importantes) y Clustering Coefficient mide la *cohesión local* (formación de grupos o módulos). Juntas con las cinco métricas base, ofrecen una visión multidimensional de la importancia de cada nodo que ninguna métrica individual puede proporcionar por sí sola.

Referencias

- [1] U. Brandes, “A faster algorithm for betweenness centrality,” *Journal of Mathematical Sociology*, vol. 25, no. 2, pp. 163–177, 2001.
<https://doi.org/10.1080/0022250X.2001.9990249>
- [2] L. Page, S. Brin, R. Motwani, T. Winograd, “The PageRank Citation Ranking: Bringing Order to the Web,” *Stanford InfoLab Technical Report*, 1999.
<https://www.cis.upenn.edu/~mkearns/teaching/NetworkedLife/pagerank.pdf>
- [3] S. Wasserman, K. Faust, *Social Network Analysis: Methods and Applications*. Cambridge University Press, 1994.

- [4] T. H. Cormen, C. E. Leiserson, R. L. Rivest, C. Stein, *Introduction to Algorithms*, 3rd ed. MIT Press, 2009.
- [5] P. Bonacich, “Power and Centrality: A Family of Measures,” *American Journal of Sociology*, vol. 92, no. 5, pp. 1170–1182, 1987.
https://web.archive.org/web/20210729125432id_/http://www.leonidzhukov.net/hse/2014/socialnetworks/papers/Bonacich-Centrality.pdf
- [6] D. J. Watts, S. H. Strogatz, “Collective dynamics of ‘small-world’ networks,” *Nature*, vol. 393, pp. 440–442, 1998.
<https://snap.stanford.edu/class/cs224w-readings/watts98smallworld.pdf>